

The 21th IEMEK Symposium on Embedded Technology (ISET2026)

"Physical AI with Embedded Systems"

일 자 : 2026년 5월 13일(수) ~ 5월 16일(토)

장 소 : 제주 그라벨 호텔

문의 및 접수처 대한임베디드공학회 Tel. 053) 801-1475 e-mail. iemek@iemek.org

주최 | IeMeK (사)대한임베디드공학회
Institute of Embedded Engineering of Korea

주관 | 경북대학교 CITAC
KYUNGPOOK NATIONAL UNIVERSITY Center for ICT & Automotive Convergence

ICTC (재)경북IT융합산업기술원
Gyeongbuk Institute of IT Convergence Industry Technology

DGIST 대구경북과학기술원
Daegu Gyeongbuk Institute of Science & Technology

Yeungnam University 정보통신연구소

IITP 정보통신기획평가원
Institute of Information & Communications Technology Planning & Evaluation

제주대학교 빅데이터연구센터
JEJU NATIONAL UNIVERSITY

KIAP 지능형자동차부품진흥원
Korea Intelligent Automotive Parts Promotion Institute

ETRI 한국전자통신연구원
Electronic and Telecommunications Research Institute

HANSAE MOBILITY

후원 | TRIZN 대보정보통신 이룸기술 (주)성일 (주)엠유포트론

일반세션

Poster Session 1 (5월 14일 (목) 9:30 - 10:30) [노꼬메홀]

* 우수논문상 수상 논문

NO.	제목	저자명	소속
1	5G Core NF의 로그데이터 분석을 위한 sLLM 학습데이터 생성 파이프라인 연구	이훈기, 김국진, 김정태	한국전자통신연구원
2*	센서 기반 행동 인식에서 아텐션 메커니즘과 계층적 설계의 성능 분석	손창식, 강원석	대구경북과학기술원
3	Intelligent Human Activity Recognition from Smartphone Sensors via Deep Temporal Modeling	Memooona, Muhammad Haseeb Hashir, 김성원	영남대학교
4	산업용 머신 비전 환경의 Sim-to-Real 유사도 수렴을 위한 MCP 기반 디지털 트윈 시뮬레이션 시스템	이종석, 김대영, 유영준	한국생산기술연구원
5	Error Dynamics in Temperature Forecasting: A Comparative Study of Baseline, Machine Learning, and Deep Learning Models	Cheng Long Bi, Hafiz Muhammad Raza ur Rehman, 최규상	영남대학교
6	히트류 영구자석 스트랩캐스팅 용탕 주입각 측정을 위한 실시간 계측 시스템 개발	이정훈	한국생산기술연구원
7	조건부 KV 캐시 재사용 기반 안드로이드 온디바이스 영상 VLM 시스템	정수인, 서경은, 김동철	한국전자기술연구원
8	Vision-Language-Action 모델을 위한 강화학습 기반실제인공지능 제어 기법	김기범, 이상문	경북대학교
9	TinyML 보상기 기반 PMSM 속도 오버슈트 저감 방법	박광민	대구경북과학기술원
10	딥러닝 기반 엣지 카메라 영상 분석을 위한 엣지 지능 제어 기법	김영기, 김동철, 양창모	한국전자기술연구원
11	Distortion-Conditioned Feature Modulation for Image Quality Assessment	Muhammad Tayyab Shehzad, 최규상	영남대학교
12	TIM Pad의 특성 평가를 위한 미세조직 분석 기법 연구	이지은, 김용휘, 변지현, 정경훈, 지상현, 김병근, 석수영	경북IT융합산업기술원
13	객체 탐지 및 단안 깊이 추정 기반 실시간 거리 측정 시스템	권동욱, 이원일	금오공과대학교
14	설명 가능한 이상행동 분류를 위한 다중 에이전트 프레임워크	장예진, 양창모, 김동철	한국전자기술연구원
15	엣지 환경에서 LLM 추론 프레임워크별 성능 비교	박시형, 이재민, 김병수, 전석훈	한국전자기술연구원
16	원격 탐사 위성의 온보드 구름 탐지를 위한 경량 영역분할 모델	박재환, 이한빈, 김형신	충남대학교
17	멀티모달 입력 기반 이벤트 검출을 위한 점수 기반 후보 갱신 기법	김우석, 양창모, 김동철	한국전자기술연구원
18	해체·재조립형 LEV 배터리팩의 열관리 신뢰성 향상을 위한 TIM Pad 적용 연구	김용휘, 김병근, 정경훈, 지상현, 변지현, 이지은, 석수영	경북IT융합산업기술원
19	이계중 엣지 AI 환경에서의 Stage-level Runtime Replanning	정진호, 김선형, 나갑주	한국전자통신연구원
20	HBM3e메모리대역폭이LLM추론안정성에 미치는 영향:H100과H200의메모리벽(MemoryWall)전이지점분석	유준영, 김지환, 정철우, 김대년	경북IT융합산업기술원

Poster Session 2 (5월 14일 (목) 10:30 - 11:30) [노꼬메홀]

* 우수논문상 수상 논문

NO.	제목	저자명	소속
1	실외 자율주행 로봇의 멀티 제어 기술	최중해, 강석진, 이서윤, 이현철, 최병재	대구대학교
2	MIMO 시뮬레이터를 이용한 60GHz FMCW 레이더 전단 모듈 검증	진영석, 현유진	대구경북과학기술원
3	신호 존재 판정 기반 저복잡도 ISAC 수신 알고리즘	김봉석, 이종훈, 김상동	대구경북과학기술원
4	터널 환경에서 조명 변화에 따른 안정적인 차량 인식을 위한 예측 기반 차량 추적	손국진, 김영덕	대구경북과학기술원
5	도심 환경에서의 드론 위험도 평가를 위한 3D 타일 기반 통합 시뮬레이션 프레임워크	윤재관, 김법곤, 김경일, 이문수	한국전자통신연구원
6	멀티센서 교차-라이다 학제 크로스모달 지식 증류를 통한 3D LiDAR 중심 E2E 자율주행 프레임워크 설계	이진희, 천영호, 박재형, 권순	대구경북과학기술원
7	도플러 속도 및 계층적 신호도 관리 기반의 mmWave 레이더 정밀 객체 추적 시스템 구현	송승언, 김봉석, 김상동, 이종훈	대구경북과학기술원
8*	라이다-카메라 크로스 모달 지식 전이 기반 3D 객체 검출 프레임워크 설계	박재형, 이진희, 김제석, 권순	대구경북과학기술원
9	MEMS 가속도센서 진동 신호 기반 비침습 엔진 회전속도 추정 시스템	이재성, 권수현, 금대현, 이성훈	대구경북과학기술원
10	BiLSTM-Adherence: Behavior-Aware Trajectory Prediction	BA TEER, HAFIZ MUHAMMAD RAZA UR REHMAN, 최규상	영남대학교
11	ChIRL: Enforcing Intention-Level Safety in Highway Lane Changing via Hierarchical Reinforcement Learning	YU JINGHUA, HAFIZ MUHAMMAD RAZA UR REHMAN, 최규상	영남대학교
12	Evidence-Grounded Fake News Detection with Retrieved Rationales and Affective Diagnostics: A Reproducible Study on CoAD	Hafiz Muhammad Raza ur Rehman, TENG YU SUN, 최규상	영남대학교
13	Deep Learning-Based Signal Reconstruction and Phase Error Calibration in 77 GHz FMCW Radar System	Danish Sharif, Sheriff Murtala, 최규상	영남대학교
14	미래차 자율주행 고도화를 위한 차량용 레이더 시스템 성능 평가 방법	배지은, 강보영, 이수성, 윤장규, 석수영	경북IT융합산업기술원
15	차량용 ECU 임베디드 시스템의 신뢰성 확보를 위한 검증항목 및 평가방안 연구	조성욱, 김승우, 권오훈, 윤장규, 석수영	경북IT융합산업기술원
16	자율주행 인지센서 오염 도로 재현성 확보 방안	김성훈, 김현보, 권오훈, 윤장규, 석수영	경북IT융합산업기술원
17	속업쇼버 구동부품 내구성 분석을 위한 구조해석 데이터 분석	정경훈, 김병근, 변지현, 김용휘, 지상현, 이지은, 석수영	경북IT융합산업기술원
18	Motion Aware Event Accumulation Analysis for Driving Scenes Using Event Cameras	Rahman Shafique, 최규상	영남대학교
19	차량 후방 카메라를 이용한 주차보조시스템 시스템 개발	박대현, 서종현, 김현보, 김용훈, 석수영	경북IT융합산업기술원
20	인캐빈 카메라 입력 이상 감지를 위한 운전자 얼굴 ROI 기반 경량 해시 기법	최봉석, 송명호, 강보영, 윤장규, 석수영	경북IT융합산업기술원

Poster Session 3 (5월 15일 (금) 16:00 - 17:00) [노꼬메홀]

* 우수논문상 수상 논문

NO.	제목	저자명	소속
1	기계학습에 의한 기어박스의 고장진단 연구: 다중 분류 · 회귀 · PCA 분석	이재천, 진성호	대구경북과학기술원
2	임베디드 제어기를 활용한 DC 모터-발전기 시스템의 샘플드 데이터 속도 제어	정두희, 최유진, 김성현	울산대학교
3	자율제조 전환이 필요한 기업 특성과 핵심 기반기술에 관한 연구	박정호	한국전자통신연구원
4	사용자 직관성 향상을 위한 시·청각 피드백 기반 신경형 맥박 모니터링 장치 구현	박영상, 정기민, 김종민	케이메디허브
5	임베디드 센서 기반 정맥주사 혼련 모듈의 디지털 전환 및 삽입력 데이터 기반 설계 연구	조중재, 박종수, 김용훈	경북IT융합산업기술원
6*	NXP S32G3 기반 vSOMEIP를 활용한 차량용 SOME/IP 서비스 구현 및 검증	김정훈, 조성래, 진성호, 이성훈	대구경북과학기술원
7	YOLO와 CLIP 기반 적응적 ROI를 활용한 rPPG 신호 품질 특징 기반 생체/비생체 판별	최락현, 강원석	대구경북과학기술원
8	AUTOSAR DEM의 최적화 설계 및 검증을 위한 통합 프레임워크 제안	권수현, 이재성, 이성훈, 금대현	대구경북과학기술원
9	홈케어 기반 DTx 행동 데이터를 활용한 ADHD 이행 분류	김승재, 김준수, 최병재, 김병일, 이현숙, 송정현, 허향숙	한국뇌연구원
10*	아동 대상 디지털 치료에서 과제 난이도 수준과 ADHD 증상 개선의 연관성	김준수, 김승재, 최병재, 김병일, 이현숙, 송정현, 허향숙	한국뇌연구원
11	저저전 배터리 사용을 위한 3단계 안전검사체계 수립과 임피던스 검사 장비 효용성 검증 시나리오 개발	김정곤, 송명호, 황형진, 김승우, 윤장규, 석수영	경북IT융합산업기술원
12	EV HV-LV Coupling Attenuation 고전압 부품의 평가방법 비교	김승우, 최현권, 권오훈, 조성욱, 김정곤, 윤장규, 석수영	경북IT융합산업기술원
13	차량용 임베디드 소프트웨어 초기 보안 검증을 위한 SIL 기반 모의해킹 자동화 환경 구축 연구	송명호, 강보영, 황형진, 김정곤, 최봉석, 윤장규	경북IT융합산업기술원
14	시선추적 기반 안구운동 디지털 인지훈련이 경도인지장애 인지 기능에 미치는 영향	이상우, 김준수, 김승재, 최병재, 천승호, 송정현	한국뇌연구원
15	리튬이온 폐배터리의 불능화 시스템	최중해, 김규인, 황병철, 박진영, 은준걸, 이기학, 김봉환	대구가톨릭대학교
16	3D 스캔 및 역설계를 활용한 고중량 전기차용 복수유로 속업쇼버의 형상 설계 및 벤치마킹 분석	변지현, 정경훈, 김병근, 김용휘, 지상현, 이지은, 석수영	경북IT융합산업기술원
17*	위험 상황 탐지 AI 학습을 위한 멀티모달 통합 어노테이션 시스템	김동철, 류지현, 양창모	한국전자기술연구원
18	STM32 및 멀티모달 센서 기반 경량형 모터 예지보전 인프라 구축	이상진, 이종훈, 류정탁	대구대학교
19	ROS2 Nav2를 위한 실시간 복셀 기반 경로 계획 플러그인 설계	김상수, 정희탁, 강지연, 유경민, 고준희	아이씨티웨이(주)

엣지 환경에서 LLM 추론 프레임워크별 성능 비교

(Performance Comparison of LLM Inference Frameworks in an Edge Environment)

박 시 형[†], 이 제 민[‡], 김 병 수[†], 전 석 훈^{‡*}

[†]한국전자기술연구원, [‡]전북대학교

(Sihyeong Park, Jemin Lee, Byung-Soo Kim, Seokhun Jeon)

([†]Korea Electronics Technology Institute, [‡]Jeonbuk National University)

Abstract : 엣지 환경에서 대규모 언어 모델을 실행하려는 수요가 증가함에 따라, 제한된 자원 조건에서 적합한 추론 프레임워크를 선택하는 문제가 중요해지고 있다. 본 연구는 Jetson Orin AGX 32 GB 기반 엣지 환경에서 Ollama와 llama.cpp로 Qwen3-0.6B, Gemma-3-4B-it, Llama-3.1-8B, Qwen3-14B의 추론 성능을 비교하였다. 실험 결과 프레임워크의 성능 순위는 모델과 부하 조건에 따라 다르게 나타났으며, 특정 프레임워크가 모든 상황에서 일관되게 우수하지는 않았다. 이를 통해 엣지 환경에서는 사용 편의성보다 목표 모델과 서비스 조건에 적합한 프레임워크를 선택하는 것이 중요함을 확인하였다.

Keywords : 엣지 컴퓨팅, 대규모 언어 모델, 추론 프레임워크, 성능 평가, 온디바이스

I. 서 론

대규모 언어 모델은 질의응답, 요약, 코드 생성, 대화형 에이전트 등 다양한 분야에서 활용되고 있다. 최근에는 개인정보 보호, 오프라인 동작, 운영 비용 절감, 서비스 응답성 개선 등의 이유로 로컬 및 엣지 환경에서 직접 실행하려는 수요가 증가하고 있다 [1, 2]. 그러나 엣지 장치는 서버 대비 연산 자원과 메모리가 제한적이므로, 모델과 추론 프레임워크의 선택이 전체 서비스 품질에 큰 영향을 준다 [3].

이러한 요구에 따라 다양한 로컬 추론 프레임워크가 개발되었다. Ollama [4]는 높은 사용 편의성과 간단한 배포 구조를 강점으로 가지며, llama.cpp [5]는 낮은 의존성과 양자화 기반 경량 실행에 강점이 있다. 두 프레임워크는 모두 로컬 환경에서 대규모 언어 모델 실행을 지원하지만, 설계 목적과 사용 방식이 달라 실제 추론 성능에도 차이가 나타날 수 있다.

본 연구는 NVIDIA Jetson Orin AGX 32 GB 기반 엣지 환경에서 Ollama와 llama.cpp의 추론 성능을 비교하였다. 실험에는 Qwen3-0.6B, Gemma-3-4B-it, Llama-3.1-8B, Qwen3-14B를 사용하였고, 성능은 Time to First Token (TTFT), Time Between Tokens (TBT), 지연시간 (Latency)을 기준으로 평가하였다. 실험 결과, 프레임워크의 성능 순위는 모델과 부하 조건에 따라 다르게 나타났으며, 특정 프레임워크가 모든 조건에서 일관되게 우수하지는 않았다. 이는 엣지 환경에서 프레임워크 선택이 단순한 사용 편의성보다 목표 모델과 서비스 조건을 함께 고려해야 하는 문제임을 시사한다.

II. 배경지식

1. Ollama

Ollama는 로컬 환경에서 대규모 언어 모델을 쉽게 실행하고 배포할 수 있도록 설계된 프레임워크이다. Go 언어 기반으로 개발되었으며, 복잡한 설정 없이 모델을 실행할 수 있고 REST API를 제공해 서비스 연동이 간단하다. 이러한 특성으로 인해 단일 장치 또는 단일 GPU 환경에 적합하다. 반면 사용 편의성을 우선하는 구조이므로 메모리 최적화나 대규모 분산 환경을 위한 지원은 제한적이다.

2. llama.cpp

llama.cpp는 대규모 언어 모델 추론을 위한

*Corresponding Author (seokhun.jeon@keti.re.kr)

박시형, 김병수, 전석훈: 한국전자기술연구원

이제민: 전북대학교

※ 이 논문은 2026년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임(RS-2024-00402898, 시뮬레이션 기반 고속/고정확도 데이터센터 워크로드/시스템 분석 플랫폼 개발).




그림 1. 모델별 입력 길이에 따른 TTFT 비교
Fig. 1. Comparison of TTFT across different input lengths for each model

C++ 기반 라이브러리이다. 의존성이 비교적 적고 x86, ARM 등 다양한 환경에서 동작하며, 자원이 제한된 환경에서도 활용할 수 있다. 특히 다양한 정밀도의 양자화를 지원하여 메모리 사용량을 줄이고, GGUF 형식을 통해 모델과 메타데이터를 일관되게 관리할 수 있다는 장점이 있다.

III. 실험 환경 및 방법

1. 실험 환경

실험은 NVIDIA Jetson Orin AGX 32 GB에서 수행하였다. 성능 비교 대상은 해당 환경에서 네이티브로 실행할 수 있는 Ollama와 llama.cpp로 한정하였다.

본 연구는 저수준 커널 벤치마크가 아니라 API 기반 종단 간 성능 평가를 목표로 하므로, OpenAI API 형식의 요청을 각 프레임워크 엔드포인트에 직접 전달하였다. 실험 모델은 HuggingFace의 Qwen3-0.6B, Gemma-3-4B-it, Llama-3.1-8B, Qwen3-14B로 구성하였다.

2. 실험 방법

본 연구에서는 성능 측정을 위해 GuideLLM [6]를 사용하였다. GuideLLM은 OpenAI API 형식의 요청과 응답을 기반으로 다양한 부하 조건을 구성할 수 있는 도구이다. 이를 이용해 동일한 형식의 요청을 생성하였으며, 엣지 장치의 처리 한계를 고려해 워크로드 크기를 다음과 같이 설정하였다.

- TTFT 측정: 입력 길이 64, 128, 256
- TBT 측정: 출력 길이 256, 512, 1024




그림 2. 모델별 출력 길이에 따른 TBT 비교
Fig. 2. Comparison of TBT across different output lengths for each model

- Latency 측정: 동시 요청 수 1, 2, 4

본 연구의 결과는 순수 연산 커널 성능이 아니라 API 처리, 프레임워크 구조, 실행 경로 등을 포함한 종단 간 성능 차이를 반영한다.

IV. 실험 결과 및 분석

1. TTFT 결과

그림 1과 같이 TTFT 결과를 보면 프레임워크의 우세가 모든 모델에서 일관되게 나타나지 않았다. Qwen3-0.6B에서는 llama.cpp가 모든 입력 길이에서 낮은 TTFT를 보였으며, Qwen3-14B에서도 전 구간에서 Ollama보다 낮은 값을 기록하였다. 반면 Llama-3.1-8B에서는 Ollama가 매우 큰 폭으로 낮은 TTFT를 보여 두 프레임워크 사이의 차이가 가장 크게 나타났다. Gemma-3-4B-it는 64 토큰 조건에서는 Ollama가 낮았지만 128과 256 조건에서는 두 프레임워크가 유사한 수준을 보였다.

이를 통해 엣지 환경에서 초기 응답성이 프레임워크 자체만으로 결정되기보다 모델 계열과 실행 경로에 민감하게 반응함을 알 수 있다. 특히 llama.cpp는 Qwen 계열 일부 모델에서 안정적인 초기 응답성을 보였고, Ollama는 Llama-3.1-8B에서 매우 강한 장점을 나타냈다.

2. TBT 결과

TBT는 그림 2와 같이 생성 구간의 지속적인 처리 효율을 나타내며, 결과는 모델별로 차이가 발생했다. Gemma-3-4B-it와 Llama-3.1-8B는 llama.




그림 3. 모델별 동시 요청 수에 따른 지연시간 비교
Fig. 3. Comparison of latency across different concurrency levels for each model

cpp가 전 구간에서 더 낮은 TBT를 기록해 보다 안정적인 토큰 생성 성능을 보였다. 반면 Qwen3-0.6B에서는 출력 길이가 길어질수록 Ollama의 TBT가 크게 낮아져 512와 1024 토큰 조건에서 llama.cpp 보다 유리한 결과를 보였다. Qwen3-14B는 256과 512 토큰에서 Ollama가 낮은 값을 보였으나, 1024 토큰에서는 llama.cpp가 소폭 우세하였다.

TBT 측면에서 llama.cpp는 전반적으로 값의 변동 폭이 작고 안정적인 경향을 보였으며, Ollama는 특정 모델과 특정 출력 길이에서 더 큰 장점을 보였다. 이는 장문 생성 환경에서 프레임워크에 따라 성능 곡선이 다르게 나타날 수 있음을 의미한다.

3. Latency 결과

전체 Latency는 그림 3과 같이 동시 요청 수가 증가할수록 모든 모델에서 증가하였다. Qwen3-0.6B와 Qwen3-14B는 llama.cpp가 전 구간에서 더 낮은 전체 지연 시간을 보였다. Gemma-3-4B-it는 두 프레임워크의 차이가 크지 않았으며, 조건에 따라 우세가 달라졌다. 가장 큰 차이는 Llama-3.1-8B에서 나타났으며, Ollama는 모든 동시 요청 수에서 llama.cpp보다 낮은 지연 시간을 기록하였다.

실제 서비스 완료 시간 관점에서 모델별 프레임워크 적합성이 크게 달라질 수 있음을 보여준다. 특히 Llama-3.1-8B와 같이 특정 모델에서는 Ollama가 동시성 증가 상황에서도 상대적으로 우수한 응답 완료 시간을 제공하였다.

V. 결론

본 연구는 Jetson Orin AGX 32 GB 기반 엣지 환경에서 Ollama와 llama.cpp의 추론 성능을 비교하였다. 실험 결과, 두 프레임워크의 성능 우위는 모델과 부하 조건에 따라 다르게 나타났으며, 특정 프레임워크가 모든 상황에서 일관되게 우수하지는 않았다. llama.cpp는 일부 Qwen 계열 모델에서 TTFT와 Latency 측면에서 강점을 보였고, Ollama는 Llama-3.1-8B와 일부 장문 생성 조건에서 우수한 성능을 나타냈다. 따라서 엣지 환경에서는 사용 편의성보다 목표 모델과 서비스 조건에 맞춘 프레임워크 선택이 중요하다.

References

- [1] H. Du, S. Wu, A. Kharlamova, N. Guan, and C. J. Xue, "Flexinfer: breaking memory constraint via flexible and efficient offloading for on-device LLM inference". Proceedings of the 5th Workshop on Machine Learning and Systems, pp.56-65, 2025.
- [2] Z. Yu, Z. Wang, Y. Li, R. Gao, X. Zhou, S. R. Bommur, Y. Zhao, and Y. Lin, "Edge-LLM: Enabling efficient large language model adaptation on edge devices via unified compression and adaptive layer voting". Proceedings of the 61st ACM/IEEE Design Automation Conference, pp.1-6, 2024.
- [3] R. Stoyanov, V. Spišáková, A. Reber, W. Armour, M. Copik, and R. Bruno, "Engine-Agnostic Model Hot-Swapping for Cost-Effective LLM Inference". Proceedings of the SC'25 Workshops of the International Conference for High Performance Computing, Networking, Storage and Analysis, pp.114-125, 2025
- [4] Ollama, "Ollama". Available: <https://ollama.com/>
- [5] ggml-org, "llama.cpp: LLM inference in C/C++". GitHub repository. Available: <https://github.com/ggml-org/llama.cpp>
- [6] vllm-project, "GuideLLM: SLO-aware Benchmarking and Evaluation Platform for Optimizing Real-World LLM Inference". GitHub repository. Available: <https://github.com/vllm-project/guidellm>