

MX/NVFP 양자화 형식의 행렬곱 실행시간 분석

오세현¹, 김용주², 이제민^{3*}

¹과학기술연합대학원대학교, ²한국전자통신연구원, ³전북대학교
somae0604@gmail.com, y.kim@etri.re.kr, jemin.lee@jbnu.ac.kr

Analysis of Matrix Multiplication Execution Time of MX/NVFP Quantization Formats

Sehyeon Oh¹, Yongjoo Kim², Jemin Lee^{3*}

¹University of Science and Technology, ²Electronics and Telecommunications Research Institute, ³Jeonbuk National University

요약

LLM 양자화에서 계층마다 서로 다른 비트 수를 할당하는 혼합 정밀도 방식은 일반적으로 각 계층의 양자화 민감도를 기준으로 비트 수를 선택한다. 민감하지 않은 계층에는 낮은 비트, 민감한 계층에는 높은 비트를 할당하는 방식이다. 이 접근은 정확도 손실을 줄이는 데 유효하지만 실제 추론 속도는 행렬곱의 입력 차원 K 와 출력 차원 N , 그리고 한 번의 행렬곱이 처리하는 토큰 수 M 의 조합에 따라 크게 변하므로, 정확도 관점에서 합리적인 선택이 속도 관점에서는 손해가 될 가능성이 있다. 본 연구는 Qwen3 1.7B와 8B의 가중치 행렬곱을 MX, NVFP 계열 네 가지 저정밀 형식으로 수행하고, 입출력 차원이 같은 행렬곱을 묶은 네 그룹 각각에서 M 을 1부터 2048까지 변화시키며 BF16 대비 행렬곱 커널 시간 기준 상대 속도를 측정하였다. 그 결과 동일 형식이라도 그룹과 M 조합에 따라 BF16 대비 최저 0.19배까지 느려지거나 최대 6.12배까지 빨라졌으며, BF16을 처음 추월하는 M 이 그룹마다 4에서 1024까지, 도달하는 최대 배율이 1.81배에서 6.12배까지 달랐다. 이는 양자화 형식 선택이 양자화 민감도뿐 아니라 속도 이득이 실제로 발현되는 조건을 함께 고려할 필요가 있음을 시사한다.

1. 서론

대규모 언어 모델의 추론 비용을 줄이기 위해 저정밀 형식을 이용한 양자화가 널리 활용된다. 최신 GPU는 블록 스케일링 기반 MX 계열[1]과 FP8 계열[2] 저정밀 형식을 텐서코어 수준에서 지원하여 BF16보다 높은 연산 처리량을 이론상 제공한다. 계층마다 다른 비트 수를 할당하는 혼합 정밀도 양자화에서는 일반적으로 각 계층의 양자화 민감도가 비트 선택의 기준이 되며, 민감하지 않은 계층은 낮은 비트로 공격적으로 양자화하고 민감한 계층은 높은 비트나 BF16으로 유지하여 전체 정확도 손실을 최소화한다.

그러나 이러한 선택은 정확도를 기준으로 삼을 뿐 실제 속도 특성을 명시적으로 다루지는 않는다. 저정밀 형식의 실측 처리량은 이론상 이득에 항상 도달하는 것은 아니며, 어떤 영역에서는 오히려 BF16보다 느려질 수 있다. 이 역전이 발생하는 조건은 행렬곱의 입력 차원 K 와

출력 차원 N , 그리고 한 번의 행렬곱이 처리하는 토큰 수 M 의 조합으로 결정되므로 민감도 정보만으로는 예측하기 어렵다. 본 연구는 Qwen3[3] 1.7B와 8B의 가중치 행렬곱을 MX, NVFP 계열 네 가지 저정밀 형식으로 수행하고, 입출력 차원이 같은 행렬곱을 묶은 네 그룹 각각에서 M 을 1부터 2048까지 변화시키며 BF16 대비 행렬곱 커널 시간 기준 상대 속도를 측정하여, 저정밀 형식이 실효 이득을 얻는 조건을 행렬곱 그룹과 M 의 함수로 정량화한다.

2. 배경

MX 표준은 동일한 텐서 안에서 인접한 32개 원소가 E8M0 형식의 공유 스케일을 사용하도록 정의하며, 각 원소는 E4M3 또는 E5M2 형식의 FP8, 혹은 E2M1 형식의 FP4로 표현된다. 채널 단위 스케일을 쓰는 표준 FP8에 비해 블록 단위 스케일은 동적 범위 부담을 분산하여 4비트 표현에서도 비교적 낮은 양자화 오차를 유지한다. NVFP4는 동일한 4비트 데이터 표현을 쓰되 블록 크기를 16으로 줄이고 스케일 자료형을 FP8 E4M3로 바꾼 변형이며, MXFP4 대비 동적 범위는 좁지만 블록당 더 정밀한 스케일을 가질 수 있다.

* 교신저자(Corresponding author)

※ 이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구 결과임(RS-2025-02214497, AI반도체를 위한 저수준 최적화 프로그램 API 기술 개발)

이러한 형식은 NVIDIA Blackwell 세대 GPU에서 텐서코어 수준의 지원을 받는다. RTX 5090을 포함한 sm_120 세대는 BF16 대비 FP8은 약 2배, FP4는 약 4배의 이론상 처리량을 제공한다. 그러나 이 이론상 처리량은 행렬 곱의 산술 집약도가 충분히 높을 때에만 발현된다. M이 작아 메모리 대역폭이 처리량을 제한하는 영역에서는 양자화로 줄어드는 연산 비용이 메모리 비용에 가려져 실효 처리량이 이론치에 미치지 못한다. 본 연구의 측정에는 이러한 행렬곱 커널이 구현된 gemlite[4] 라이브러리를 사용한다.

비트 폭을 정하는 혼합 정밀도 양자화의 관행은 일반적으로 정확도 측에 초점을 둔다. GPTQ[5], AWQ[6], QuaRot[7], SpinQuant[8] 계열의 양자화 기법은 가중치와 활성 분포의 통계, 예컨대 헤시안 행렬이나 활성 이상치 등을 분석하여 정확도 손실을 최소화한다. 이 방식은 정확도 측면에서는 효과적이지만, 실측 실행시간 측면은 양자화 정책 결정에 반영되지 않는다. 본 연구는 정확도 측 대신 속도 측에서 이 갭을 정량화하여, 민감도와 속도 두 축의 결합이 필요한 이유를 측정으로 보인다.

3. 실험 및 결과

측정 환경은 sm_120 세대 NVIDIA RTX 5090이고, 양자화 커널은 gemlite 라이브러리의 구현을 이용하였다. 각 조합에서 워밍업 5회 후 50회 반복의 평균 실행시간을 측정하고 동일 조건의 BF16 실행시간을 기준으로 상대 속도를 계산한다. 행렬곱 커널의 실행시간 자체를 비교하기 위해 활성 양자화 커널은 측정 루프 밖에서 한번만 수행하고, 루프 안에서는 행렬곱 커널만을 호출한다. BF16 경로는 활성 양자화가 없으므로 커널 호출 시간이 곧 행렬곱 시간이다. 비교 대상은 네 가지 저정밀 형식이다. A8W8/A4W4 MXFP는 입력 가중치를 각각 8/4 비트 MX 형식으로 표현하며 32원소 블록 스케일을 사용하고, A4W4 NVFP는 4비트이되 블록 크기 16, 스케일 FP8 E4M3를 쓴다. A8W8 FP8은 블록 스케일 없이 채널별 스케일을 쓰는 표준 FP8이다. 네 형식의 스케일 구조는 표 1과 같다.

표 1. 본 연구가 비교한 저정밀 형식.

형식	스케일 단위	스케일 자료형
A8W8 MXFP	32원소 블록	E8M0
A4W4 MXFP	32원소 블록	E8M0
A4W4 NVFP	16원소 블록	FP8 E4M3
A8W8 FP8	채널별	FP32

Qwen3 트랜스포머[9] 블록 안의 가중치 행렬곱 일곱개는 입출력 차원이 같은 것끼리 묶어 네 그룹으로 정리한다. 어텐션 블록의 쿼리·출력 계층 q_proj와 o_proj를

묶은 attn_qo, 키·밸류 계층 k_proj와 v_proj를 묶은 attn_kv, MLP 블록의 게이트·상항 계층 gate_proj와 up_proj를 묶은 mlp_gate_up, 그리고 MLP의 하항 단독 계층 mlp_down이며, 각 그룹의 차원은 표 2와 같다. 입출력 차원 K, N은 모델 정의로 고정되지만 토큰 수 M은 서빙 단계에 따라 크게 달라진다. 디코드 단계에서는 동시 처리 요청 수가 그대로 M이 되어 1에서 수십 수준이며, 프리필 단계에서는 입력 컨텍스트를 한꺼번에 또는 청크 단위로 처리하므로 수백에서 수천 수준이 된다[10].

표 2. Qwen3 행렬곱 그룹과 차원. M은 2^0에서 2^11까지 변화시키며 측정.

모델	그룹	M	N	K
Qwen3 1.7B	attn_qo	2^n	2048	2048
	attn_kv		1024	2048
	mlp_gate_up		6144	2048
	mlp_down		2048	6144
Qwen3 8B	attn_qo	2^n	4096	4096
	attn_kv		1024	4096
	mlp_gate_up		12288	4096
	mlp_down		4096	12288

BF16 대비 상대 속도는 자료형별 텐서코어 이론 처리량 비율을 참조 기준으로 한다. 즉 측정값이 이 비율에 얼마나 가깝거나 이를 넘어서는지가 그룹과 M 조합이 만들어내는 효율 차이를 보여준다. RTX 5090의 자료형별 피크 처리량은 표 3과 같다. FP8 계열은 BF16의 2배, FP4 계열은 4배의 피크 처리량을 가진다.

표 3. RTX 5090 텐서코어의 피크 TFLOPS.

자료형	피크 TFLOPS	BF16 대비
BF16	209.5	x1
FP8	419	x2
MXFP8	419	x2
MXFP4	838	x4
NVFP4	838	x4

이 이론 비율 대비 실측이 어떤 그룹과 M 조합에서 어디까지 도달하거나 이를 넘어서는지가 본 연구의 비교 대상이며, 측정 결과는 그림 1에 정리된다. M이 작은 영역에서는 대부분의 그룹·형식 조합이 BF16 대비 0.19에서 0.51배에 머물러 오히려 느렸다. 다만 K, N이 큰 그룹은 일찍 추월이 시작되어, Qwen3-8B mlp_down은 A4W4_MXFP 기준 M=4부터, mlp_gate_up은 M=32부터 BF16을 앞섰다. 반면 K, N이 작은 attn_kv는 Qwen3-1.7B에서 M=1024에 이르러서야 BF16을 추월해 M=2048에서도 1.81배에 그쳤고, Qwen3-8B에서도 정점이 M=2048에서 3.29배로 다른 그룹보다 일관되게 낮았다.




그림 1. M에 따른 BF16 대비 상대 속도.

M이 커지면 K, N이 큰 그룹을 중심으로 BF16 대비 이득이 빠르게 누적되었다. Qwen3-8B mlp_gate_up은 A4W4_MXFP 기준 M=512에서 6.12배로 정점에 도달했고, mlp_down은 M=2048에서 4.87배에 이르렀다. 같은 그룹을 Qwen3-1.7B에서 측정하면 mlp_gate_up이 BF16을 추월하는 M이 256으로 낮춰지고 정점도 M=1024에서 5.41배에 그쳐, 동일 형식이라도 모델 규모에 따라 이득이 나타나는 시점과 크기가 함께 변했다.

같은 그룹 안에서도 BF16 대비 이득은 비트 폭에 따라 달라졌다. Qwen3-8B mlp_gate_up에서는 4비트 형식이 BF16의 5.73배에서 6.12배까지, 8비트 형식이 3.17배에서 3.64배까지 도달하였다. 반대로 Qwen3-1.7B attn_kv에서는 네 형식 모두 1.70배에서 1.81배 범위에 머물렀다.

이 결과는 양자화 민감도만으로 비트를 결정하는 방식이 속도 측면에서 놓치는 부분을 보여준다. 같은 4비트 형식을 모든 그룹에 균일하게 적용한다고 가정하면 Qwen3-8B mlp_gate_up에서는 M=512에서 6.12배 이득이 가능하지만, Qwen3-1.7B attn_kv에서는 M=1024에 이르러서야 BF16과 같아지고 그 이전 모든 M에서는 더 느리다. 이처럼 교차 M과 정점 배율이 그룹마다 크게 다른 만큼 양자화 민감도 분포와 자동으로 정렬된다고 볼 근거는 없다. 따라서 민감도만을 기준으로 비트를 결정하면 속도 이득이 큰 그룹을 BF16에 유지하거나 이득이 발현되지 않는 M 영역에서 동작하는 그룹을 저비트로 돌리는 어긋남이 생길 여지가 있다.

4. 결 론

본 연구는 RTX 5090 환경에서 Qwen3 1.7B와 8B의 가중치 행렬곱을 MX, NVFP 계열 네 가지 저정밀 형식으로 수행하고, 입출력 차원이 같은 행렬곱을 묶은 네 그룹 각에서 M을 1부터 2048까지 변화시키며 BF16 대비 행렬곱 커널 시간 기준 상대 속도를 정량화하였다. 저정밀 형식이 BF16보다 빨라지는 영역은 입출력 차원 K, N과 토큰 수 M의 조합으로 결정되며, 모델과 그룹에 따라 교차 M이 4부터 1024까지 달라진다. 이는 민감도만을 기준으로 낮은 비트를 할당하는 방식이 속도가 발현되지 않는 M 영역에서 동작하는 그룹을 저비트로 돌리거나 큰 이득이 가능한 그룹을 BF16에 유지하는 어긋남을 만들 수 있음을 시사한다. 양자화 형식 선택은 계층별 양자화 민감도와 함께 각 그룹이 속도 이득을 얻는 M 범위를 함께 고려할 필요가 있으며, 전체 그룹에 단일 형식을 적용하는 대신 이득이 발현되는 그룹에 선택적으로 적용하는 혼합 방식이 실질적 처리량 향상에 더 효과적일 수 있다. 본 결과는 RTX 5090, gemlite 라이브러리, Qwen3 1.7B와 8B에 한정된 측정에 기반하며, 다른 GPU 세대·라이브러리·모델 규모에서의 일반화와 활성 양자화 커널을 포함한 전체 추론 단계의 실효 이득 분석, 그리고 정확도와 속도를 함께 고려한 그룹 단위 형식 선택 정책의 자동 탐색을 향후 과제로 남긴다.

참고문헌

- [1] B. D. Rouhani et al., "With Shared Microexponents, A Little Shifting Goes a Long Way," in Proc. ISCA, 2023.
- [2] A. Kuzmin et al., "FP8 Quantization: The Power of the Exponent," in Proc. NeurIPS, 2022.
- [3] A. Yang et al., "Qwen3 Technical Report," arXiv:2505.09388, 2025.
- [4] H. Badri and A. Shaji, "GemLite: Lightweight Triton Kernels for Low-Bit Linear Inference," GitHub repository, <https://github.com/mobiusml/gemlite>, 2024.
- [5] E. Frantar, S. Ashkboos, T. Hoefler, and D. Alistarh, "GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers," in Proc. ICLR, 2023.
- [6] J. Lin et al., "AWQ: Activation-aware Weight Quantization for On-Device LLM Compression and Acceleration," in Proc. MLSys, 2024.
- [7] S. Ashkboos et al., "QuaRot: Outlier-Free 4-Bit Inference in Rotated LLMs," in Proc. NeurIPS, 2024.
- [8] Z. Liu et al., "SpinQuant: LLM Quantization with Learned Rotations," in Proc. ICLR, 2025.
- [9] A. Vaswani et al., "Attention Is All You Need," in Proc. NeurIPS, 2017.
- [10] W. Kwon et al., "Efficient Memory Management for Large Language Model Serving with PagedAttention," in Proc. ACM SOSP, 2023.